



Ensemble Learning

UP: GL/BD

Réalisé par : Equipe ML Appliqué



Objetifs du cours



Comprendre le fonctionnement des arbres de décision et leur rôle en apprentissage supervisé.



Découvrir les méthodes d'ensemble learning pour améliorer les performances des modèles.



Expliquer le principe du Random Forest



Partie 1:

Decision tree



Plan


1. Objectifs du cours
2. Introduction
3. Arbre de décision



Introduction

Un arbre de décision est un modèle supervisé, prédictif qui utilise une structure arborescente pour prendre des décisions basées sur des règles.

C'est une technique de classification hiérarchique descendante.






Structure d'un arbre



Decision Tree





Structure d'un arbre

Les composants de l'arbre :

- **Nœud Racine (Root Node) :**

C'est le point de départ de l'arbre. C'est le premier critère qui permet de diviser l'ensemble des données en sous-groupes plus homogènes.

- **Nœuds de Décision (Decision Nodes) :**

Ce sont les nœuds intermédiaires qui continuent à diviser les données en fonction d'autres critères.

- **Feuilles (Leaf Nodes) :**

Ce sont les nœuds terminaux qui donnent la décision finale ou la prédiction (catégorielle ou continue).



Les étapes de construction de l'arbre de décision

1. Choisir un attribut de dataset
2. Calculer la **signification** de l'attribut dans le fractionnement de données (discrimination).
3. Fractionner les données en fonction de la valeur de meilleur attribut (le plus discriminant)
4. Allez vers chaque branche et répéter ces étapes pour le reste des attributs
5. Prédiction: Utiliser l'arbre pour la prédiction des nouveaux cas.


Conditions d'arrêt du partitionnement :

- Lorsque la cible donne la même classe pour tout le groupe.
- Lorsqu'on n'obtient aucun résultat.
- Lorsqu'il ne reste plus aucun attribut à utiliser pour diviser.



Surapprentissage (Overfitting)

- L'arbre devient trop complexe et s'adapte trop aux données d'entraînement.
- Cela diminue sa capacité à généraliser sur de nouvelles données.



- Permet de simplifier l'arbre après sa construction
- Supprime les branches inutiles ou peu fiables
- Réduit le surapprentissage



Quel attribut est significatif(discriminant) ?

Choix du nœud

On choisit l'attribut le plus pur:

- Celui où tous les exemples sont de la même classe
- Celui qui sépare le mieux les exemples positifs et négatifs
- C'est l'attribut le plus discriminant

Mesure d'impureté :

- ✓ Entropie de Shannon
- ✓ Entropie de Boltzmann
- ✓ **Index de Gini**



C'est quoi l'Indice de gini ?

- L'**indice de gini** est la mesure de **hasard** dans les données.
- L'indice de gini dans un nœud dépend de la quantité de données aléatoires dans ce nœud et est calculée pour chaque nœud => *l'homogénéité* des exemples dans un nœud



Nous cherchons les arbres avec le faible indice de gini dans leurs nœuds.

Algorithmes d'apprentissage

CART

[Breiman, 1984]

ID3

[Quinlan, 1986]

SIPINA

[Zighed, 1992]

C4.5

[Quinlan, 1993]



Algorithme CART

Il utilise l'indice de Gini qu'on cherche à minimiser:

$$IG = 1 - \sum_{i=1}^N f_i^2$$

- f_i fréquence de la classe c_i dans le nœud
- N : nombre de classes à prédire

➡ **Plus l'indice de Gini est bas, plus le nœud est pur**



Avantages et inconvénients

Avantages

- Facile à comprendre.
- Modèle visuel et interprétable.
- Pas besoin de normaliser les données.
- Peut gérer des données numériques et catégorielles.

Inconvénients

- Ils peuvent devenir trop complexes, ce qui nuit à leur capacité de généralisation (surapprentissage).
- Sensible au bruit (petits changements des données).
- La construction de l'arbre ne garantit pas d'obtenir l'arbre optimal.



Partie 2:

Random Forest




Plan

1. Introduction
2. Techniques d'Ensemble Learning
3. Random Forest



Introduction : Qu'est-ce que l'ensemble learning ?


L'ensemble learning est une technique de machine learning où plusieurs modèles sont combinés pour résoudre un problème et améliorer les performances par rapport à un modèle unique.



➡ Réduire le sur-apprentissage (overfitting) et augmenter la précision.



Techniques d'ensembles learning





Techniques d'ensembles learning

Techniques d'ensembles learning

Bagging

- On construit plusieurs modèles indépendants sur différents sous-ensembles aléatoires des données.
- Les prédictions sont combinées (vote majoritaire pour classification, moyenne pour régression).
- **Exemple** : Random Forest.


Boosting

- Les modèles sont construits séquentiellement, chaque modèle corrige les erreurs du précédent.
- **Exemple** : AdaBoost, XGBoost.



Random Forest

Random Forest est un ensemble d'arbres de décision (Decision Trees) construits via la technique de bagging, où chaque arbre est entraîné sur un échantillon aléatoire des données et une sélection aléatoire de caractéristiques.



- Permet de réduire l'overfitting et d'améliorer la précision.
- Convient pour classification et régression.



Caractéristiques (Features) de Random Forest

- Plusieurs arbres de décision indépendants.
- Sélection aléatoire des sous-ensembles de données et de features.
- Prédiction finale par vote majoritaire (classification) ou moyenne (régression).
- Résistant au bruit et outliers.
- Capable de mesurer l'importance des variables (feature importance).



Random Forest : Etapes


- **Étape 1** : Dans ce modèle, nous sélectionnons un sous-ensemble de points de données et un sous-ensemble de caractéristiques pour construire chaque arbre de décision. En termes simples, nous prenons n enregistrements aléatoires et m caractéristiques dans un ensemble de données contenant k enregistrements.
- **Étape 2** : Nous construisons des arbres de décision individuels pour chaque échantillon.
- **Étape 3** : Chaque arbre de décision génère une sortie.
- **Étape 4** : Nous considérons la sortie finale en fonction du vote majoritaire pour la classification et de la moyenne pour la régression, respectivement.



Random Forest : Exemple

Prédire le type de fruit.

- Chaque arbre de décision donne une prédiction (classe).
- Le Random Forest combine toutes les prédictions par vote majoritaire.
- Résultat final = fruit le plus voté (ici, Banane).





Hyperparamètres principaux

n_estimators

Nombre d'arbres dans la forêt.

max_depth

Profondeur maximale de chaque arbre.

min_samples_split

Nombre minimum d'échantillons pour diviser un noeud.

min_samples_leaf

Nombre minimum d'échantillons dans une feuille.

max_features

Nombre de features à considérer à chaque split.

bootstrap

Utiliser ou non le bootstrap.



Avantages et inconvénients

Avantages

- **Précision élevée** : combine plusieurs arbres pour améliorer la performance par rapport à un arbre de décision simple.
- **Robustesse** : moins sensible au surapprentissage et aux données bruitées ou incomplètes.
- **Analyse des variables** : permet d'évaluer l'importance des caractéristiques pour la sélection de variables.

Inconvénients

- Random forest est plus complexe que les arbres de décision, où l'on prend des décisions en suivant le chemin de l'arbre.
- En raison de sa complexité, le temps d'apprentissage est plus long que celui des autres modèles. Chaque fois qu'il doit effectuer une prédiction, chaque arbre de décision doit générer une sortie à partir des données d'entrée fournies.